Dipartimento Politecnico di Ingegneria e Architettura (DPIA)
Corso di Visione Artificiale

Progetto: 3D Printing Defects Classification

Studente: Lorenzo Zaccomer
Data: 17 dicembre 2022

Estratto

Progetto svolto per il corso di Visione Artificiale tenuto dal Professore Andrea Fusiello nell'anno accademico 2021/2022.
Lo scopo di questo progetto è quello di generare un modello convoluzionale in linguaggio Python, affinché possa determinare, da un'immagine passata come parametro, la difettosità o meno di un pezzo stampato mediante una stampante 3D.

Indice

1 Introduzione

1.1 La stampante 3D

La stampante 3D è un dispositivo attorno al quale vi ruota un grosso interesse al giorno d'oggi, questo perché è impiegabile in molti campi applicativi, sia in ambito industriale, sia in ambito *user level*, poiché essa permette un grosso risparmio in termini di costi progettuali, sopratutto in fase di prototipizzazione.

Con una spesa iniziale non troppo elevata per la stampante in sé (200€ per un modello base), essa permette a chi si interfaccia per la prima volta a questo mondo, di stamparsi i pezzi desiderati, magari anche progettati da autodidatta, inoltre il suo utilizzo è facilitato dalla presenza di svariati tool di disegno grafico presenti sul mercato, come per esempio *OpenSCAD*, il quale è open-source e scaricabile gratuitamente, inoltre grazie alla comunità di *Thingiverse*, gli utenti possono condividere i propri progetti, ed infine con *UltimakerCura*, è possibile modificare le impostazioni di stampa.

A livello di materiali, quello maggiormente impiegato per le stampe è il PLA, la quale è una plastica non tossica.

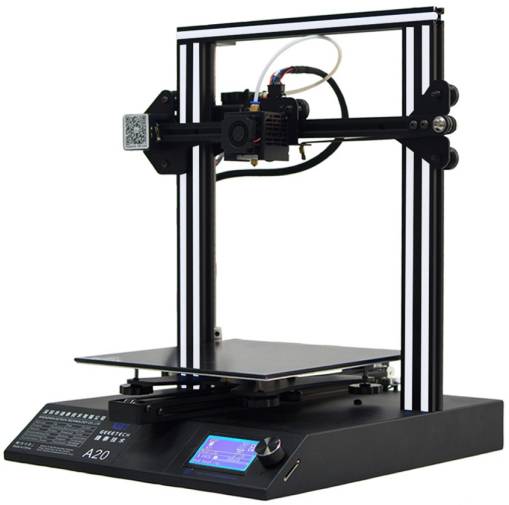

Figura 1.1: Esempio di stampante 3D, modello Geeetech A20

1.2 Descrizione del problema

Il problema legato all'utilizzo è per esempio è il rumore emesso dall'elettronica e dalle componenti meccaniche, per cui è necessario posizionarla in un'altra stanza, il più lontano possibile, anche nel caso in cui si impieghi una box dedicata, così facendo il problema si attenua ma non scompare, perciò questa problematica legata al rumore rende impossibile un controllo *a vista* dell'esecuzione di stampa, per cui in caso di problemi si rischia di far proseguire la stampa per ore, con uno spreco di materiale di stampa e di tempo.

La difettosità del pezzo ha una forte dipendenza dalla **temperatura**, in particolare essa è legata a più elementi, ovvero:

- la *stanza* stessa cui si trova la stampante
- il *piano di adesione* della stampa
- l'*ugello* (nozzle) della stampante

Questo perché se la temperatura di questi tre elementi non è adeguata, si rischia una ritrazione del pezzo, con conseguente difettosità della stampa.

Nel primo caso è maggiormente risolvibile, riscaldando adeguatamente la stanza , anche un classico scalda bagno è più che sufficiente.

Nel secondo caso l'ugello deve lavorare alla temperatura di fusione del materiale in uso (200° per il PLA); questo parametro è programmabile dalla stampante stessa tramite interazione con lo schermo, questo perché se la temperatura è troppo bassa, il filamento non si scalda e la stampa non viene eseguita, invece se la temperatura è troppo alta, il filamento rischia di fare quello che si chiama in gergo *effetto spaghetto*, il quale può causare un danneggiamento estetico del pezzo ed un impedimento al movimento nel nozzle se si deposita sul punto sbagliato.

Figura 1.2: Esempio dell'effetto spaghetto

Per quanto riguarda il piano di adesione, le temperature operative si aggirano dai 30° agli 80°, però se la temperatura scelta non è adeguata, si rischia che in un caso, ovvero con una temperatura troppo bassa, la base del pezzo si solidifichi troppo, facendo si che esso si *stacchi completamente* dal piano, o in effetto minore provochi il sollevamento di una sua parte, infine se le temperature del piano sono troppo elevate, in maniera duale il pezzo non si raffredda nella maniera corretta, rischiando di produrre delle pieghe sulle superficie esterne del pezzo.

Tale problema di sollevamento del pezzo è mitigabile programmando un layer aggiuntivo di stampa attorno al pezzo, impostabile mediante UltimakerCura.

Perciò l'addetto alla stampa, deve tenere conto di una moltitudine di possibili eventi, sopratutto nel caso in cui un pezzo richieda della ore per essere generato.

1.3 Nascita dell'idea per questo progetto

L'idea nasce quando mi è stata regalata una stampante 3D (Figura 1.1) e le problematiche descritte nelle righe precedenti le ho affrontate in prima persona durante l'utilizzo della stessa, ho pensato per mesi a come minimizzare il problema, ma grazie ad un insieme di fattori e dall'opportunità datami da questo corso, tutto questo mi ha spronato a sviluppare questa idea che vi sto presentando.

2 Descrizione del progetto

In questa sezione si andrà ad analizzare le scelte tecniche fatte per l'implementazione e una descrizione ai soli punti salienti, piuttosto ché una descrizione riga per riga del codice stesso, inoltre si darà un'infarinatura generale dei concetti teorici che verranno citati.

2.1 Introduzione

Lo scopo di questo progetto è quello di generare un modello, nello specifico una rete convoluzionale, affinché possa determinare da un'immagine di un pezzo prodotto da una stampante 3D se esso sia difettoso oppure no, questo dopo un'attività di training, per fare ciò ho utilizzato la tecnica del *Transfer Learning*.

2.2 Transfer Learning

Tale tecnica permette di addestrare il nostro modello *campione* mediante un modello di training, pre-esistente e già pre-allenato, il quale ha avuto a disposizione un ampio dataset di immagini (attorno al milione) per svolgere il suo allenamento, per cui è in grado di classificare correttamente le immagini, mentre il nostro modello non ha un dataset così ampio per essere allenato correttamente, a me piace utilizzare l'esempio del personal trainer in palestra per descrivere questa tecnica.

2.3 Struttura del codice

Esso si compone di 3 layer principali:

- classification.py (GitHub)
- model.py (GitHub)
- cartella libraries

Il primo file (**classification.py**), permette l'esecuzione vera e propria della classificazione delle immagini, in particolare è fissata per default una sola immagine (7.jpg), e su schermo verrà visualizzata l'immagine con un testo che ne indica la predizione, associata ad una percentuale, come indicato in Figura 2.1.

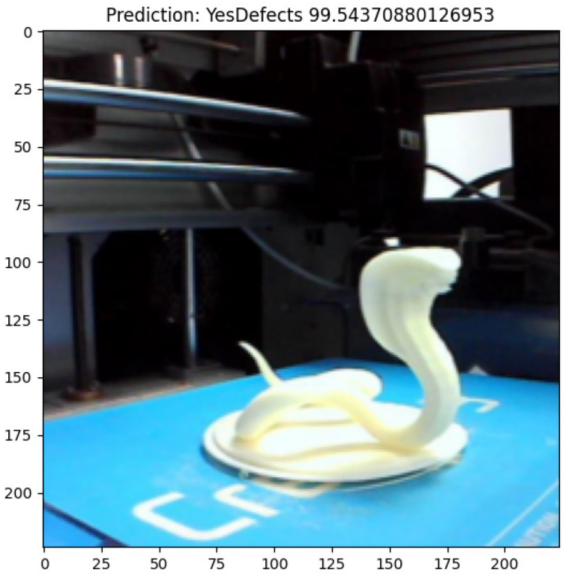

Figura 2.1: Esempio di predizione che viene prodotta

Ho implementato inoltre anche una parte di compilazione personalizzata del codice affinché l'utente possa effettuare un *tuning* molto veloce di alcuni parametri, come per esempio il learning rate, il percorso delle immagini e così via senza mettere mano al codice, con conseguente ricompilazione.
Per esempio:

```
yourpath\3D-printer-recognition>python .\Project\classification.py
↪  --test_image_path './Images\\classification-images\\9.jpg'
```

Codice 2.1: Primo esempio di compilazione personalizzata

In questo caso vogliamo cambiare l'immagine di test che verrà visualizzata, mentre in questo altro caso si può personalizzare il numero di epoch.

```
yourpath\3D-printer-recognition>python ./Project/classification.py
↪  --epochs 3
```

Codice 2.2: Secondo esempio di compilazione personalizzata

Il secondo file (**model.py**), racchiude tutte le funzionalità necessarie per la generazione del modello e la sua visualizzazione, includendo quindi due funzioni specifiche per questo compito, vedasi le funzioni citate (ModelGeneration e LoadModelVisualization) presenti listato 2.4.

Mentre nella cartella **libraries**, sono contenuti tutti quei file aventi tutte le altre funzioni "minori" che vengono impiegate, questo solamente per un fattore estetico e visivo migliore, ottimizzando la scrittura e il debugging.

Infine, è stata implementata tutta una sequenza di logging affinché essi vengano salvati su uno file specifico, questo permette di facilitare il debugging rispetto al piazzare delle print in giro per il codice.

2.4 Funzionamento

Si va ad eseguire dall'IDE il file classification.py, il quale inizialmente effettua un controllo sui parametri che vengono passati dalla linea di comando[1] e se ci sono errori nella scelta dei parametri l'esecuzione viene terminata immediatamente, questo per far sì che non si verifichino problemi durante l'esecuzione del codice stesso, troncando l'esecuzione sul nascere, questo controllo viene svolto mediante la seguente funzione:

```
CheckParametersErrors(option.epochs, option.learning_rate,
↪  option.iteration, option.visualize_prediction,
↪  option.test_image_path, option.model_path,
↪  option.dataset_images_path)
```

Codice 2.3: Controllo errori (classification.py)

Successivamente, in base all'opzione di iterazione scelta, si passa o meno alla funzione che genera il nostro modello:

```
if option.iteration == 1:
    print('execution of model generation function')
    ModelGeneration(option.dataset_images_path, option.model_path,
    ↪  option.epochs, option.learning_rate)
elif option.iteration == 0 and option.visualize_prediction == 1:
    print('skip model generation, it loads the model from path and
    ↪  visualize the results')
    LoadModelVisualization(option.dataset_images_path,
    ↪  option.model_path)
    exit()
else:
    print("loading image classification ..")
```

Codice 2.4: Opzione di iterazione (classification.py)

Si hanno quindi tre modalità operative in base al valore di due flag che gli vengono passati, *iteration* e *visualize prediction*, dove se:

[1] O dal file launch.json se si utilizza il debugger di Visual Studio Code

- *iteration = 1*, allora **viene eseguito tutto il codice**, ovvero la generazione e salvataggio del modello, la visualizzazione del modello con un numero di immagini pari al valore del *batch size*[2], questo prelevando delle immagini randomiche dal dataset "mixato", ed infine viene eseguita la classificazione dell'immagine di prova.

- *iteration = 0 e visualize prediction = 1*, in questo caso viene eseguita **solamente la visualizzazione della predizione**, saltando la generazione del modello, questo può tornare utile per fare più prove sullo stesso modello senza rigenerarlo continuamente.

- *iteration = 0 e visualize prediction = 0*, **è il caso di default**, ovvero viene eseguita solamente la classificazione dell'immagine desiderata, saltando la parte di generazione del modello e la visualizzazione della predizione, ed utilizzando come modello da caricare quello indicato nel percorso specifico.

Proseguiamo ora con la prima scelta.

Per la generazione del modello quello che si svolge in partenza è estrarre due dataset di immagini, aventi con riferimento due cartelle differenti, *train* e *valid* nel nostro caso, dove la prima è molto più grande dell'altra, e si esegue un mix (shuffle) tra questi due dataset in modo da renderli indistinguibili, prelevando un numero randomico di immagini da entrambi i dataset, nello specifico questo viene svolto dalla seguente funzione:

```
def ShuffleDatasets(dataset, subs):
    "This function takes the datasets and shuffle them"

    """Not set num_workers because this settings can create
    ↪  compiling error,so leave the default value"""
    return {x: DataLoader(dataset[x], batch_size=4, shuffle=True)
    ↪  for x in subs}
```

Codice 2.5: Funzione ShuffleDatasets (datasets.py)

In questo caso ho lasciato il numero di num workers[3] al valore di default (0) perché altrimenti genera un *multi processing error* su sistemi Windows.

Si passa quindi all'elaborazione vera e propria del modello che vogliamo allenare, per cui inizialmente viene caricato il modello di pre-allenato:

```
pretrained_model = models.resnet50(pretrained=True)
```

Codice 2.6: Caricamento del modello pre-allenato (model.py)

[2]Numero di immagini che si vogliono utilizzare per generare il modello per iterazione
[3]Numero di sotto processi che si possono eseguire

In questo caso ho scelto il modello resnet50, poiché l'ho trovato molto valido rispetto ad altre opzioni, come per esempio il resnet18.

Infine, dopo aver creato i parametri di ottimizzazione, si passa al training del modello desiderato:

```
starting_time = time.time()
generated_model = train_model(mixed_datasets, dataset_sizes,
↪  pretrained_model, criterion, optimizer_ft, exp_lr_scheduler,
↪  EPOCH_NUMBER)
logging.info('Training time: {:10f}
↪  minutes'.format((time.time()-starting_time)/60))
```

Codice 2.7: Training del modello (model.py)

Successivamente il modello viene salvato localmente nella directory specificata e se ne visualizzerà la predizione:

```
logging.info("saving the model ..")
torch.save(generated_model, MODEL_PATH)
logging.info("model saved!")

logging.info("visualize generated model ..")
visualize_generated_model(mixed_datasets, labels, generated_model)
print("closing ..")
```

Codice 2.8: Predizione del modello (model.py)

Infine, se tutto è andato nel verso giusto, si esce da questa funzione e si torna al file classification.py, il quale avrà il mero compito a questo punto di caricare il modello precedentemente creato dalla directory specificata e l'immagine che vogliamo classificare e visualizzarla, come in Figura 2.1.

Inoltre l'utente avrà a disposizione un file di log generato nella directory principale per visualizzare tutti i parametri desiderati e l'andamento di tutti i passaggi svolti dal programma.

3 Risultati

I risultati all'inizio erano molto variabili, ovvero dipendevano fortemente in base a come si concludeva la generazione del modello, ottenendo risultati molto buoni oppure predizioni completamente errate, per cui dopo alcune simulazioni, e fissando i seguenti parametri:

learning rate [4] = 0.05
epoch [5] = 1
modello pre-allenato = resnet50

Il modello ha cambiato completamente comportamento, aumentando di molto la precisione, puntando però ad essere leggermente aggressivo, ovvero a vedere l'errore anche dove non si trova in alcuni frame, ma con una generale corretta predizione per l'errore; in questo caso il tempo di training per questo modello è sull'ordine di qualche minuto, questo a causa del basso numero di epoch, impostato solamente per ridurre il tempo delle simulazioni stesse in fase di scrittura del codice.

Inoltre è da considerare il fatto che i risultati sono fortemente influenzati da:

modello di pre-allenamento (resnet18, resnet50, alexnet, ...)
optimizer (SGD, Adam, ...)
learning-rate-scheduler
parametri di tuning (epoch, learning rate, ...)

Questo perché per ognuno di questi parametri esistono molte varianti utilizzabili, per cui la scelta risulta molto complessa.
Successivamente, per ottenere una buona precisione anche per i pezzi non difettosi, ho modificato il numero di iterazioni, fissando il numero di epoch a *25*, ciò ha richiesto circa 35 minuti per processare il modello, così facendo ho trovato un buon grado di accuratezza nella predizione delle immagini, in entrambi i casi, laddove prima si arriva ad una accuratezza del 76%, ora in vece è pari all'88%.

Alla pagina successiva è possibile visualizzare i risultati ottenuti per alcune immagini di test.

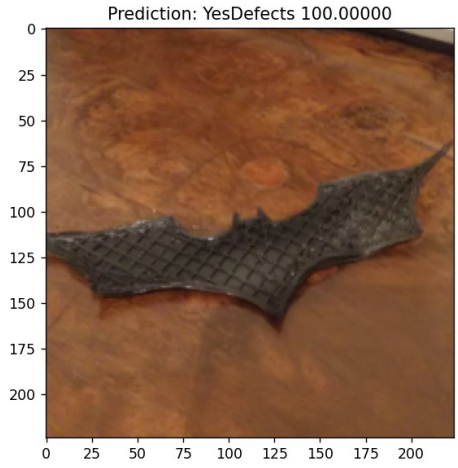

(a) Pezzo difettoso: Predizione corretta

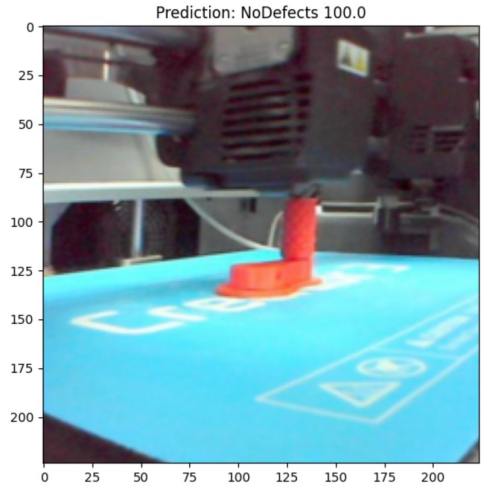

(b) Pezzo non difettoso: Predizione corretta

Figura 3.1: Primo esempio di predizioni

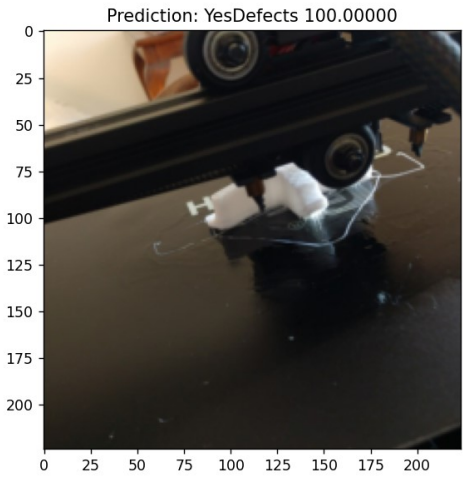

(a) Pezzo difettoso: Predizione corretta

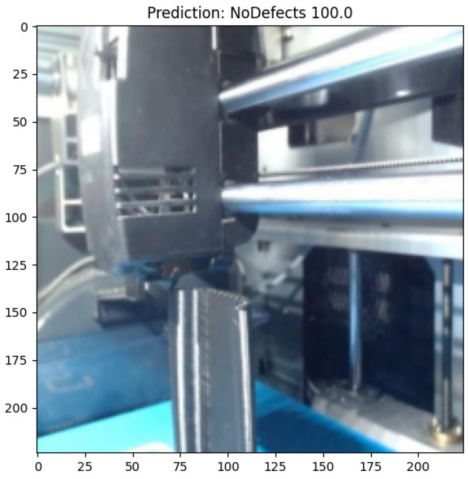

(b) Pezzo non difettoso: Predizione errata

Figura 3.2: Secondo esempio di predizioni

4 Conclusioni

Penso che questo progetto possa essere una valida alternativa, se sviluppata nel modo corretto, ad altre soluzioni già presenti, questo perché mostra una buona accuratezza nel svolgere la predizione, inoltre il salvataggio del modello in locale permette di essere utilizzato su dispositivi molto meno potenti di un computer, come per esempio un Raspberry Pi, e utilizzare quest'ultimo solo come mero osservatore dello sviluppo della stampa.

Inoltre come idea si può pensare di dare una maggiore specificità all'errore trovato, per esempio:

- *NoDefects - Spaghetti*
- *NoDefects - Lift*

Questo sarebbe fattibile modificando le cartelle immagini e aggiungendo le opportune cartelle.

Inoltre volendo, mediante le deduzioni fatte precedentemente, il frame da classificare può essere prelevato direttamente dalla fotocamera.

In conclusione ritengo che questo sia solo un punto di partenza per molte altre idee alle quali questo progetto può legarsi.